

Data Mining HW1 Report

- Student Name: 林浩君
- Student ID: 0816124

Problem 1 - How do you select features for your model input, what preprocessing did you do?

- 首先分析所需預測的資料，我們會有每一天的 18 種不同的測量指標及前 9 個小時的資料，想要預測出第 10 小時的 PM2.5 資料，所以將模型的 input & output 定為：
 - Input: $18 \text{ attributes} * 9 \text{ hours} = 162 \text{ features}$
 - Output: One single scalar
- 再來分析所擁有的資料，想辦法切出上面想要的 input & output。我們有 2021 年 1~12 月每月前 20 天的資料，其中每天有 18 種不同的測量指標及一天 24 小時的資料。
 1. 根據資料類型，我將每 10 天做為區隔切出一個 unit，這樣總共切出 $12 \text{ month} * 2 \text{ unit per month} = 24 \text{ unit}$ ，而每個 unit 的維度是將每天根據時間維度 concatenate 在一起，所以變成 $(18, 24 \text{ hours} * 10 \text{ days}) = (18, 240)$

```
Data unit of every 10 days: 24  
Data size of each unit: (18, 240)
```
 2. 以每一個 unit 為單位，根據 4 : 1 的比例去切 training / validation dataset。所以預計分別會有 19 / 4 unit。
 3. 再來對於每一個 unit，我想要獲得盡可能多的 data 以便讓訓練效果變好，所以我會每 10 小時就切成一個 data (example shown below)，所以每個 unit 能夠生成 $240 - 10 + 1 = 231 \text{ training data}$ 。
 - example: Assume we have 12 hours of data, we can transfer it into $12 - 10 + 1 = 3 \text{ training data}$.
 - i. input: [1-9] hours, output: 10 hours

ii. input: [2-10] hours, output: 11 hours

iii. input: [3-11] hours, output: 12 hours

- Total Dataset Size

- Training Dataset: $231 * 19 = 4389$

- Validation Dataset: $231 * 5 = 1155$

```
Size of trainX: (4389, 162), trainY: (4389,)
Size of validX: (1155, 162), validY: (1155,)
```

- 切好 training / validation dataset 後，就可以根據現有的 dataset 來做 data preprocessing，我做了以下幾點來幫助訓練：

1. Missing Value Imputation，因為原始的資料有相當數量的 missing value ('#', '*', 'x', 'A')，需要把那些值補起來才能夠正常訓練。而我利用線性內插 (Linear Interpolation) 去做 value imputation。


```
for index, row in enumerate(unit):
    row = row.astype(np.float32)
    indices = np.isnan(row)
    x = np.arange(len(row))

    row[indices] = np.interp(
        x[indices],
        x[~indices],
        row[~indices]
    )
```

2. Standardization，因為原本每個 attribute 的 scale 差距非常多，所以我多做了 standardization 來讓他訓練的過程更順利。而為了保證每一個 data preprocessing 的步驟都保持一致，我在每一個 dataset (training / validation / testing) 上都利用 training dataset 的 mean & standard deviation 去做 standardization。

Problem 2 - Compare the impact of different training data amounts on the PM2.5 prediction accuracy, visualize the result and explain it.

- 根據上面的結論可以看到我們總共有 4389 個 training data，所以我們探討不同的 training data size 對於同等 validation dataset 下的 RMSE 影響，結果為下圖所示。
- 可以看到 training data size 對 performance 的影響還是蠻大的，特別是在 data size < 2000 時的 RMSE 下降的很快。而 data size > 2000 後 RMSE 下降的趨勢稍微趨緩了，但是整體的損失值還是有持續在下降的。特別注意到根據圖中的曲線可以看到 training loss 普遍都比 validation loss 低一點，所以我們的 model 有輕微的 overfitting。



Problem 3 - Discuss the impact of regularization on PM2.5 prediction accuracy.

- Regularization 是在 loss function 上加上一項額外的 weight 的項，透過這個操作讓他的 weight 值不會到太大，所以預測曲線就不會太過曲折，進而降低 overfitting 的

現象。而我實作了 L2 Regularization (formula shown below)，看看不同的 lambda 值對於 performance 的影響，這邊只有在 gradient descent 的時候用 regularization，而評量 performance 的還是原本的 RMSE，結果如下圖所示。

- L2 Regularization: $L(f(x)) = \sum(y_i - \hat{y}_i) + \lambda \cdot \sum w_i^2$
- 根據圖中曲線可以看到隨著 lambda 增加，training loss 也會隨著增加，這跟預想中的一樣因為 regularization 會減少 model 的泛化能力。接著看到 validation loss，他有一個先變低再變高的趨勢，代表 regularization 是能夠稍微解決 overfitting 的問題，而最佳的參數落在曲線的最低點，即為 lambda = 0.1。注意到這個最佳 lambda 可能會根據不同的 preprocessing method 或不同的參數設定而有所不同。

