

Data Mining HW3 Report

- Student Name: 林浩君
- Student ID: 0816124

1. Explain your implementation which get the best performance in detail.


- 這次作業是想要去對資料做分群，而我們有的 training data 只有少數幾種 label。我想到的方法是可以先訓練一個模型去在 training data 上做分類，而當我們在 testing data 上面做預測時，如果是在訓練時沒有遇過的 outlier 模型應該會很難去區分他，所以預測出來的機率分佈就會很平均，而在數學的角度上我就以 `entropy` 的大小做為判斷的依據。由此為出發點我依序做了下面步驟：
1. 我選擇用 `RandomForestClassifier()` 做為分類器，可以看到他在我切出來的訓練集與測試集上的準確率都非常高

```
model = RandomForestClassifier(random_state=42)
model.fit(X_train, y_train)


print("Training Accuracy:", accuracy_score(y_train, model.predict(X_train)))
print("Validation Accuracy:", accuracy_score(y_valid, model.predict(X_valid)))
```

```
Training Accuracy: 1.0
Validation Accuracy: 0.975
```

2. 接著在將模型對 training data 上的所有資料做預測，並將結果的 `entropy` 做視覺化



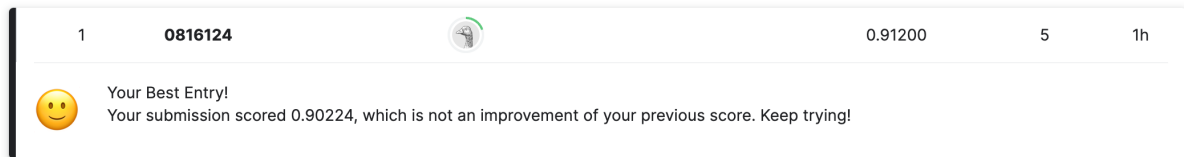
3. 同樣的方法對 testing data 做視覺化，可以看到比較大的 entropy 明顯變多了



4. 根據觀察兩個 histogram，我選擇以 0.9 作為切割生成最終的預測結果

```
y_pred = [1 if entropy > 0.9 else 0 for entropy in entropies]
df = pd.DataFrame({
    'id': [i for i in range(1000)],
    'outliers': y_pred
})
df.to_csv('submission.csv', index=False)
```

5. 最終我在 Kaggle public leaderboard 上拿到 0.912 的 auc score



2. Explain the rationale for using auc score instead of F1 score for binary classification in this homework.

- 根據 AUC score 與 F1 score 的計算方法我們可以發現，F1 score 更適合正樣本和負樣本時有相同的重要性時，而 AUC score 更適合去凸顯正常樣本和異常樣本的區分能力。這次作業做的是異常檢測，所以重要的是盡可能抓出多的異常樣本，我猜這可能是選擇 AUC score 的原因。

3. Discuss the difference between semi-supervised learning and unsupervised learning.

- semi-supervised learning 運用少量標記數據和大量未標記資料進行訓練，期望從未標記資料中學習到更多有用的信息，以提高模型的泛化能力。
- unsupervised learning 則是在完全缺乏標記數據的情況下進行訓練，通常針對 clustering, dimension reduction 與 generative 等問題，能夠幫助發現資料中的潛在結構和特徵。